

엣지 배포를 위한 비전 파운데이션 모델 기반 단안 깊이 추정의 Tensor RT 최적화: 지연시간-정확도 트레이드오프 분석

박민선, 현준희, 박선우, 조정태, 박하늘, 배강현, 한동일*

세종대학교 컴퓨터공학과

e-mail : 22ppark@gmail.com, hyeonjunhee@gmail.com, seonu123@naver.com,
chogyeeongtae7453@gmail.com, haneulpark7275@gmail.com, qorkdgus111@naver.com,
dihan@sejong.ac.kr

TensorRT-Based Latency-Accuracy Trade-off Analysis of Foundation Model Monocular Depth Estimation for Edge Deployment

Minsun Park, Junhee Hyeon, Seonu Park, Haneul Park, Kanghyun Bae, Dongil Han*

Sejong University

Abstract

Recent monocular depth estimation models built on vision foundation backbones achieve strong zero-shot generalization but pose challenges for real-time deployment on resource-constrained devices. This paper presents a systematic analysis of TensorRT-based optimization for foundation-model-based monocular depth estimation on a consumer-grade mobile GPU, using Depth Anything V2 as a representative case study. We evaluate three model variants (ViT-S, ViT-B, ViT-L) under FP32 and FP16 precision, measuring inference latency, layer-wise computational breakdown, GPU memory footprint, and depth estimation accuracy on the NYU Depth V2 validation set. Experimental results show that FP16 conversion yields 4.4× to 4.8× speedup

over FP32 with negligible accuracy degradation (AbsRel difference under 0.0002 across all variants). The ¹smallest variant under FP16 achieves 233 FPS while maintaining $\delta_1 = 0.899$, demonstrating that mobile-GPU edge deployment of foundation-model-based depth estimation is feasible without architectural modification. Layer-wise profiling further reveals that, under FP32 baseline, 81~82% of inference time is concentrated in the DINOv2 backbone consistently across all model sizes, while FP16 conversion alters this distribution by accelerating attention layers most aggressively, raising the relative share of the DPT decoder head to 23~33%. These findings provide direct guidance for future compression efforts targeting both the backbone and the decoder components.

I. 서론

* 교신저자: 한동일

단안 깊이 추정(monocular depth estimation)은 자율주행, 로봇 조작, 증강현실 등 다양한 응용 분야의 핵심 기술이다. 최근 이 분야에서는 대규모 사전학습된 비전 파운데이션 모델을 backbone으로 활용하고 지식 증류 [1] 기반 학습 파이프라인을 결합하는 접근이 SOTA(State-of-the-Art)로 자리잡고 있으며 [2, 3], DINOv2 [4]와 같은 자기지도 학습 backbone을 활용하면서 zero-shot 환경에서도 우수한 일반화 성능을 보이고 있다.

그러나 이러한 모델은 Vision Transformer(ViT) [5] 기반의 큰 backbone을 채택하고 있어, 모바일 GPU나 엣지 디바이스 환경에서의 실시간 추론에는 여전히 한계가 존재한다. 산업 현장에서는 정확도뿐 아니라 실제 배포 가능성, 즉 지연시간(latency)과 메모리 사용량 또한 핵심 평가 지표가 되므로, 파운데이션 모델 기반 깊이 추정 모델이 모바일급 환경에서 어느 수준의 성능을 보이는지에 대한 정량적 벤치마크가 필요하다.

본 연구에서는 Depth Anything V2의 세 가지 크기 변형(ViT-S, ViT-B, ViT-L)를 NVIDIA TensorRT [6]로 최적화하고, 모바일 클래스 GPU 환경에서 다음 네 가지를 측정하였다: (1) FP32 및 FP16 정밀도에서의 추론 지연시간, (2) 레이어 단위 계산 분포, (3) GPU 메모리 사용량, (4) NYU Depth V2 [7] 검증 셋에서의 정확도. 본 연구의 기여는 다음과 같다. 첫째, 파운데이션 모델 기반 깊이 추정 모델의 모바일 GPU 환경 실측 벤치마크를 제공한다. 둘째, FP16 변환이 정확도를 거의 손상시키지 않으면서 4.4~4.8배의 속도 향상을 달성함을 정량적으로 입증한다. 셋째, 모델 크기와 정밀도 조합 중 실시간 엣지 배포에 가장 적합한 구성을 제시한다. 넷째, TensorRT IProfiler 기반 레이어 단위 분석을 통해 FP32 baseline에서 backbone이 추론 시간의 81~82%를 일관되게 차지하고 FP16에서 그 비율이 어떻게 변동하는지를 정량화하여, 향후 backbone 및 decoder 경량화 우선순위에 대한 실증적 근거를 제시한다.

II. 본론

2.1 대상 모델 및 실험 환경

본 연구에서는 Depth Anything V2의 세 가지 backbone 변형을 비교 대상으로 선정하였다. ViT-Small (24.8M 파라미터), ViT-Base (97.5M), ViT-Large (335.3M)이며, 각 모델은 affine-invariant disparity를 출력하도록 사전학습된 가중치를 그대로 사용한다.

실험 환경은 NVIDIA RTX 4070 Laptop GPU (8GB VRAM), CUDA 12.4, TensorRT 10.x, Pytorch 2.x로 구성하였다. 모든 추론은 단일 GPU 단일 배치(batch size = 1) 조건에서 수행되었다. 입력 해상도는 모든 변형에 대해 동일하게 518 × 518로 고정하였다.

2.2 변환 파이프라인

그림 1은 본 연구에서 사용한 전체 변환 및 측정 파이프라인을 보여준다. PyTorch 모델은 PyTorch → ONNX(opset 17) → Simplified ONNX → TensorRT Engine 경로로 변환된다. ONNX(Open Neural Network Exchange) 변환 시 모델의 forward 함수는 정규화된 (1, 3, 518, 518) 텐서만 입력으로 받도록 래퍼(wrapper)로 재구성하였다. TensorRT 빌드 시 workspace 메모리는 4GB로 제한하였으며, FP16 모드에서는 BuilderFlag.FP16 플래그를 활성화하였다. 동일한 ONNX 모델로부터 FP32 및 FP16 두 가지 엔진을 각각 빌드하여 정밀도에 따른 성능 차이를 비교하였다.




그림 1. 본 연구의 변환 및 측정 파이프라인

2.3 측정 방법

지연시간은 CUDA event를 사용한 GPU 측 타이밍으로 측정하였다. 호스트-디바이스 동기화 오버헤드를 제외한 순수 추론 시간만 포함하기 위해, 입력 텐서를 사전에 GPU 메모리에 로드한 후 50회의 warm-up과 200회의 본 측정을 수행하였다. 결과는 mean, median, p95, p99 통계량으로 보고한다. GPU 메모리 사용량은 추론 중 NVML(NVIDIA Management Library) API를 통해 측정하였다.

정확도는 NYU Depth V2 검증 셋의 654개 샘플에 대해 평가하였다. Depth Anything V2의 출력이 affine-invariant disparity이므로, ground-truth depth를 disparity 공간으로 변환한 후 robust median-based scale-shift alignment를 수행하고, 이를 다시 depth로 환원하여 표준 metric (AbsRel, RMSE, $\log_{10}$, δ_1 , δ_2 , δ_3)을 산출하였다.

III. 구현

3.1 종합 성능 비교

표 1은 6개 모델-정밀도 조합에 대한 종합 측정 결과를 보여준다.

표 1: NYU Depth V2 종합 벤치마크 결과

Model	Prec.	Latency	FPS	δ_1	AbsRel	VRAM
ViT-S	FP32	20.61	48.5	0.899	0.091	756
ViT-S	FP16	4.28	233.5	0.899	0.091	598
ViT-B	FP32	59.55	16.8	0.912	0.083	1138
ViT-B	FP16	12.22	81.8	0.913	0.083	754
ViT-L	FP32	166.01	6.0	0.915	0.082	2202
ViT-L	FP16	37.39	26.7	0.915	0.082	1270

3.2 지연시간-정확도 트레이드오프

그림 2는 6개 조합의 지연시간-정확도 관계를 시각화한 것이다. 모든 모델에서 FP16 변환은 일관되게 4.4~4.8배의 속도 향상을 달성하였다. 가장 작은 ViT-S/FP16은 233 FPS로 30 FPS 실시간 처리 기준을 큰 폭으로 상회하였으며, ViT-B/FP16 또한 실시간 응용이 가능한 수준을 보였다. 반면 ViT-L은 FP16 적용 후에도 30 FPS에 미달하여 본 환경에서의 실시간성에는 한계가 있다.




그림 2. Latency-Accuracy 트레이드오프

한 가지 주목할 점은 모델 파라미터 비율(1 : 3.93 : 13.52)에 비해 FP16 지연시간 비율(1 : 2.84 : 8.73)이

상대적으로 작다는 사실이다. 이는 ViT의 attention 연산 복잡도가 파라미터 수보다 토근 수에 더 크게 의존하기 때문으로, 큰 모델일수록 파라미터 한 개당 추론 비용이 상대적으로 작음을 시사한다. 또한 본 GPU의 Tensor Core 아키텍처가 ViT 계열의 GEMM(General Matrix Multiplication) 연산에 효과적으로 작용한다는 점도 함께 작용한 것으로 분석된다.

3.3 정확도 보존

표 1에서 확인되듯, FP32와 FP16 간 정확도 차이는 모든 모델에서 측정 노이즈 수준에 해당하여 사실상 손실 없는 FP16 변환임을 확인할 수 있다. 이는 ViT 계열에서 빈번하게 사용되는 LayerNorm [8]의 정규화 분포가 FP16 변환에 강건하다는 기존 관찰과 일치한다. 모델 크기에 따른 정확도 향상은 ViT-S < ViT-B < ViT-L 순으로 단조 증가하였다.

그림 3은 NYU 검증 셋의 4개 샘플에 대한 PyTorch, TensorRT FP32, TensorRT FP16의 depth map 출력을 비교한 것이다. 시각적으로 세 결과 사이에는 식별 가능한 차이가 없으며, 이는 정량적 분석 결과와 일치한다.




그림 3. 정성적 비교

3.4 레이어 단위 지연시간 분석

본 절에서는 TensorRT 엔진의 IProfiler API를 통해 각 레이어의 추론 시간을 측정하고, 카테고리별로 집계하여 모델 내부의 지연시간 분포를 분석한다. 카테고리는 backbone(DINOv2 encoder)의 attention, FFN(Feed-Forward Network), LayerNorm, patch embedding과 Dense Prediction Transformer(DPT) [9] decoder head로 구분하였다.

표 2와 그림 4는 6개 조합의 레이어 단위 분석 결과를 보여준다. 분석을 통해 세 가지 주요 관찰을

도출할 수 있다.

첫째, FP32 baseline에서는 backbone이 차지하는 비율이 모델 크기와 무관하게 81~82% 수준으로 일관되게 나타났다. 이는 Depth Anything V2 아키텍처에서 backbone이 구조적으로 큰 비중을 차지함을 의미하며, FP16 변환을 적용하지 않은 기본 환경에서 backbone이 경량화의 가장 큰 영향 요소임을 시사한다.

둘째, FP16 변환은 backbone에 더 큰 속도 향상을 가져왔으며, 그 결과 카테고리별 비율 또한 변화하였다. FP16에서는 backbone 비율이 65~76%로 감소하는 한편 DPT head의 상대 비중은 23~33%까지 증가하였다. 즉 FP16 변환만으로 주요 병목이 backbone에서 head로 부분적으로 옮겨가며, 이는 FP16 환경에서는 backbone뿐 아니라 DPT head 부분의 최적화도 함께 고려할 가치가 있음을 보여준다.

셋째, FP16 변환에 따른 속도 향상 폭은 카테고리별로 균일하지 않게 나타났다. 특히 attention 연산의 속도 향상이 가장 컸으며, 이는 FFN과 LayerNorm의 속도 향상 폭을 크게 웃돌았다. 반면 LayerNorm [8]은 원소별 연산 비중이 높아 FP16 변환에 따른 속도 향상 폭이 작다.

이러한 분석은 Depth Anything V2의 향후 경량화 방향에 두 가지 시사점을 제공한다. FP32 환경에서는 backbone 경량화가 전체 지연시간 감소에 가장 크게 기여하는 요소가 된다. 반면 FP16 환경에서는 backbone이 이미 Tensor Core로 속도가 향상되어 있으므로, 추가적인 지연시간 개선을 위해서는 DPT head의 구조적 최적화도 동등하게 고려되어야 한다.




그림 4. 레이어 단위 지연시간 분포

(a) 절대 시간, (b) 비율

표 2: 카테고리별 지연시간 비율 (%)

Category	ViT-S	ViT-L	ViT-B	ViT-T	ViT-M	ViT-XL
----------	-------	-------	-------	-------	-------	--------

	S/FP3 2	S/FP1 6	B/FP3 2	B/FP1 6	L/FP3 2	L/FP1 6
Attention	55.4	24.0	48.5	21.9	45.5	20.3
FFN	15.5	25.3	21.5	36.6	24.5	37.5
LayerNorm	2.2	4.8	1.7	3.0	1.5	3.2
DPT Head	17.4	33.4	15.6	23.9	15.5	23.5
Backbone	6.5	8.9	9.8	11.9	10.2	14.6
Other	3.0	3.6	2.8	2.7	2.8	0.9
Backbone Total	81.0	65.0	82.2	75.0	81.9	76.1

3.5 종합 분석

본 측정 결과는 ViT-S/FP16 구성이 모바일 클래스 GPU 환경에서 실시간 엡지 배포에 가장 적합함을 보여준다. 다만 정확도를 우선시하는 응용에서는 ViT-B/FP16이 합리적인 대안이 된다. FP16 변환은 모든 모델에서 사실상 손실 없는 최적화로 확인되어, 별도의 정확도 복원 기법 없이 기본 적용이 권장된다.

IV. 결론 및 향후 연구 방향

본 연구는 비전 파운데이션 모델 기반 단안 깊이 추정이 별도의 아키텍처 수정이나 파인튜닝 없이도 모바일 클래스 GPU 환경에서 실시간 추론에 도달할 수 있음을 정량적으로 입증했다. FP16 변환만으로 모든 변형에서 4.4~4.8배의 속도 향상이 AbsRel 기준 0.0002 이하의 정확도 손실로 달성되었으며, 이는 정확도 복원 기법 없이도 FP16 변환을 그대로 사용할 수 있음을 의미한다. 특히 ViT-S/FP16 구성은 30 FPS 실시간 기준선의 약 8배에 해당하는 233 FPS를 $\delta_1 = 0.899$ 의 정확도와 함께 달성하여, 깊이 정보를 입력으로 사용하는 후속 처리 단계에 충분한 계산 여유를 제공하는 실시간 베이스라인으로 활용될 수 있다.

또한 레이어 단위 분석은 정밀도 환경에 따라 경량화 전략이 차별화되어야 함을 보여준다. FP32 baseline에서는 backbone이 추론 시간의 81~82%를 일관되게 차지하므로 backbone 경량화가 단일한 우선순위가 되지만, FP16 환경에서는 이 비율이 65~76%로 감소하고 DPT head의 상대 비중이 23~33%까지 상승한다. 따라서 FP16 배포를 전제하는 후속 경량화 연구는 backbone과 DPT head를 동등한 우선순위로 다루어야 한다는 실증적 근거를 본 연구가 제공한다.

이러한 결과를 바탕으로 다음 두 방향을 우선순위로 후속 연구를 계획하고 있다. 첫째, FP16 환경의 분석 결과가 시사하는 backbone-DPT head 동시 경량화를 진행한다. 둘째, 본 연구에서 구축한 측정 인프라를 INT8 양자화 환경 및 Jetson Orin 임베디드

디바이스에 확장 적용하여, 본 결과의 일반화 가능성을 검증한다.

감사의 말

본 연구는 2026년 과학기술정보통신부 및 정보통신기획평가원의 연구 결과로 수행되었으며 (IITP-2023-RS-2022-00156354) 또한 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업 지원을 받아 수행되었음 (2024-0-00037)

참고문헌

- [1] G. Hinton, O. Vinyals, and J. Dean, "Distilling the Knowledge in a Neural Network," NeurIPS Deep Learning Workshop, 2015.
- [2] L. Yang, B. Kang, Z. Huang, X. Xu, J. Feng, and H. Zhao, "Depth Anything: Unleashing the Power of Large-Scale Unlabeled Data," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024, pp. 10371–10381.
- [3] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth Anything V2," Advances in Neural Information Processing Systems (NeurIPS), 2024.
- [4] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, et al., "DINOv2: Learning Robust Visual Features without Supervision," Transactions on Machine Learning Research (TMLR), 2024.
- [5] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, et al., "An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale," International Conference on Learning Representations (ICLR), 2021.
- [6] NVIDIA Corporation, "TensorRT Developer Guide," NVIDIA Documentation, 2024. [Online]. Available: <https://docs.nvidia.com/deeplearning/tensorrt>
- [7] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, "Indoor Segmentation and Support Inference from RGBD Images," European Conference on Computer Vision (ECCV), 2012.
- [8] J. L. Ba, J. R. Kiros, and G. E. Hinton, "Layer

Normalization," arXiv preprint arXiv:1607.06450, 2016.

- [9] R. Ranftl, A. Bochkovskiy, and V. Koltun, "Vision Transformers for Dense Prediction," Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2021, pp. 12179–12188.